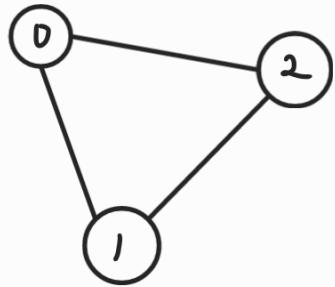


Graph (G)



$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \quad D = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

$$\therefore L = D - A = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}$$

$$Lx = \begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

$$= \begin{bmatrix} 2x_1 - x_2 - x_3 \\ -x_1 + 2x_2 - x_3 \\ -x_1 - x_2 + 2x_3 \end{bmatrix} = \begin{bmatrix} (x_1 - x_2) + (x_1 - x_3) \\ (x_2 - x_1) + (x_2 - x_3) \\ (x_3 - x_1) + (x_3 - x_2) \end{bmatrix} = \begin{bmatrix} \sum (x_i - x_1) \\ \sum (x_i - x_2) \\ \sum (x_i - x_3) \end{bmatrix}$$

Convolution Theorem

$$H(z) = \int_{-\infty}^{\infty} f(x) g(z-x) dx$$

$$\mathcal{F}\{f*g\}(v) = \mathcal{F}\{f\}(v)$$

$$\begin{aligned} &= \int_{-\infty}^{\infty} h(z) e^{-2j\pi v z} dz \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x) g(z-x) e^{-2j\pi v z} dx dz \\ &= \int_{-\infty}^{\infty} f(x) \left(\int_{-\infty}^{\infty} g(z-x) e^{-2j\pi v z} dz \right) dx \quad u = z-x \\ &= \int_{-\infty}^{\infty} f(x) \left(\int_{-\infty}^{\infty} g(u) e^{-2j\pi v (u+x)} du \right) dx \\ &= \int_{-\infty}^{\infty} f(x) e^{-2j\pi v x} dx \int_{-\infty}^{\infty} g(u) e^{-2j\pi v u} du \end{aligned}$$

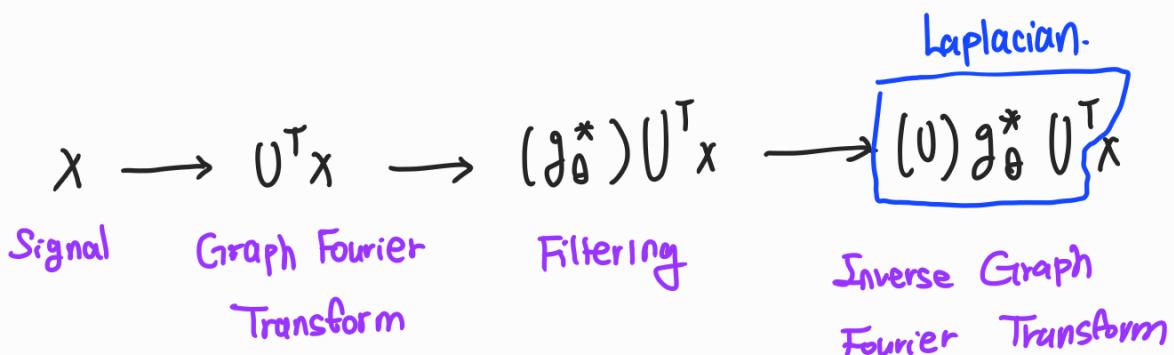
⇒ convolution 연산은 Fourier Transform의 multiplication으로 표현 가능.

Graph domain에서 Filter와 signal의 convolution의 의미는
node feature

Laplacian Matrix의 eigen decomposition 결과와 signal의 곱과 같다.

$$f * g = F^{-1} \{ F\{f\} \cdot F\{g\} \}$$

$$g_\theta * x = F^{-1}(F(x) \odot F(g)) = U(U^T x \odot U^T g)$$



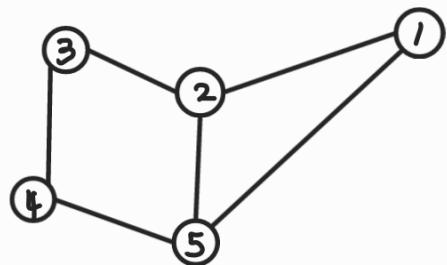
$$\underbrace{g_\theta}_\text{Filter} * \underbrace{x}_\text{signal} = U g_\theta^* U^T x$$

$$g_\theta = \begin{bmatrix} \hat{g}(\lambda_1) & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \hat{g}(\lambda_N) \end{bmatrix}$$

$$g_{\theta}(\lambda) = \sum_{k=0}^K \theta_k \lambda^k = \theta_0 \lambda^0 + \theta_1 \lambda^1 + \dots + \theta_K \lambda^K$$

$$\begin{aligned} x * g_{\theta} &= U \sum_{k=0}^K \theta_k \lambda^k U^T x \\ &= U (\theta_0 \lambda^0 + \theta_1 \lambda^1 + \dots + \theta_K \lambda^K) U^T x \\ &= \sum_{k=0}^K \theta_k L^k x \end{aligned}$$

Localized Feature (k-hop)



$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{bmatrix} \quad D = \begin{bmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 3 \end{bmatrix}$$

$$L = D - A \quad \begin{bmatrix} 2 & -1 & 0 & 0 & -1 \\ -1 & 3 & -1 & 0 & 1 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & -1 \\ -1 & -1 & 0 & -1 & 3 \end{bmatrix}$$

1hop

$$Lx = \begin{bmatrix} 2 & -1 & 0 & 0 & -1 \\ -1 & 3 & -1 & 0 & 1 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & -1 \\ -1 & -1 & 0 & -1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} \sum_{i \in [2,3]} (x_1 - x_i) \\ \sum_{i \in [1,3,5]} (x_2 - x_i) \\ \sum_{i \in [2,4]} (x_3 - x_i) \\ \sum_{i \in [3,5]} (x_4 - x_i) \\ \sum_{i \in [1,2,4]} (x_5 - x_i) \end{bmatrix}$$

$$L(Lx) = \begin{bmatrix} 2 & -1 & 0 & 0 & -1 \\ -1 & 3 & -1 & 0 & 1 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & -1 \\ -1 & -1 & 0 & -1 & 3 \end{bmatrix} \begin{bmatrix} \sum_{i \in [2,3]} (x_i - x_1) \\ \sum_{i \in [1,3,5]} (x_i - x_2) \\ \sum_{i \in [2,4]} (x_i - x_3) \\ \sum_{i \in [3,5]} (x_i - x_4) \\ \sum_{i \in [1,2,4]} (x_i - x_5) \end{bmatrix}$$

$$= \begin{bmatrix} 2 \sum_{i \in [2,3]} (x_i - x_1) - \sum_{i \in [1,3,5]} (x_i - x_2) - \sum_{i \in [1,2,4]} (x_i - x_5) \\ -\sum_{i \in [2,3]} (x_i - x_1) + 3 \sum_{i \in [2,3]} (x_i - x_2) - \sum_{i \in [2,4]} (x_i - x_3) + 3 \sum_{i \in [1,2,4]} (x_i - x_5) \\ -\sum_{i \in [1,3,5]} (x_i - x_2) + 2 \sum_{i \in [1,3,5]} (x_i - x_3) - \sum_{i \in [3,5]} (x_i - x_4) \\ -\sum_{i \in [2,4]} (x_i - x_3) + 2 \sum_{i \in [3,5]} (x_i - x_4) - \sum_{i \in [1,2,4]} (x_i - x_5) \\ -\sum_{i \in [2,3]} (x_i - x_1) - \sum_{i \in [1,3,5]} (x_i - x_2) - \sum_{i \in [3,5]} (x_i - x_4) + 3 \sum_{i \in [1,2,4]} (x_i - x_5) \end{bmatrix}$$

첫번째 행만 보면

$$\underbrace{2 \sum_{i \in [2,3]} (x_i - x_1)}_{\text{node 1과 그 이웃의 정보.}} - \underbrace{\sum_{i \in [1,3,5]} (x_i - x_2)}_{\text{node 2와 그 이웃의 정보}} - \underbrace{\sum_{i \in [1,2,4]} (x_i - x_5)}_{\text{node 5와 그 이웃의 정보}}$$

→ central node의 이웃의 이웃까지 feature 활용

$L^k x \Rightarrow k\text{-hop의 이웃정보 포함.}$

ChebNet

parameterization을 통해 Localized feature 추출 가능.

But computation complexity \uparrow 높음.

\Rightarrow Chebyshev polynomial of first kind로 대체

$$g_\theta = \sum_{i=0}^K \theta_i T_i(\tilde{\lambda}), \quad \tilde{\lambda} = \frac{2\lambda}{\lambda_{\max}} - I_n \quad (-1 < \tilde{\lambda} < 1)$$

범위 scaling

$$T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x) \quad \left(T_0(x) = 1, T_1(x) = x \right)$$

Chebyshev polynomial of first kind

$$x * g_\theta = U \left(\sum_{i=0}^K \theta_i T_i(\tilde{\lambda}) \right) U^T x \quad L = \frac{2L}{\lambda_{\max}} - I_n$$

$$x * g_\theta = \sum_{i=0}^K \theta_i T_i(L) x$$

GCN

ChebNet에서 크게 3단계의 변화를 중.

Step 1: $K=1, \lambda_{\max} = 2$

Step 2: $\theta = \theta_0 = -\theta_1$

Step 3: $I_n + D^{-1/2} A D^{-1/2} \rightarrow \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$

Step 1

$K=1$ 로 정하고 activation function을 통해 non-linearity를 추가해 layer를

깊게 쌓는 방식으로 만듬. $\lambda_{\max} = 2$ 로 가정.

$$x * g_\theta = \sum_{i=0}^K \theta_i T_i(L) x$$

$$\Rightarrow x * g_\theta = \theta_0 x - \theta_1 (L - I_n) x$$

Step 2

$\theta = \theta_0 = -\theta_1$ 와 같이 parameter를 줄여서 overfitting을 방지

$$x * g_\theta = \theta (I_n + D^{-1/2} A D^{-1/2}) x$$

Step 3

$$I_n + D^{-1/2} A D^{-1/2} \rightsquigarrow \text{eigenvalue } [0, 2] \text{ 범위를 가짐}$$

Renormalization trick을 통해 eigenvalue의 최댓값의 크기를 줄여줌.

$$I_n + D^{-1/2} A D^{-1/2} \rightarrow \tilde{D}^{-1/2} \tilde{A}^{-1/2} \tilde{D}^{-1/2}$$

$$(\tilde{A} = A + I_n, \tilde{D}_{ii} = \sum_j \tilde{A}_{ij})$$

Self-loop를 추가하여 oversmoothing 방지.

Eigenvalue의 범위를 줄여서 연산과정 전체의 stability 확보.

$$x * g_\theta = \theta \tilde{D}^{-1/2} \tilde{A}^{-1/2} \tilde{D}^{-1/2}$$

↓ 일반화

$$H^k = \sigma(A H^{k-1} \theta^k)$$

$$\hat{A} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}, (R^{n \times n})$$

$$H^0 = X, (X \in R^{n \times C})$$

$$H^k \in R^{n \times F} \xrightarrow{\text{output channel } \uparrow} K\text{번째 layer output}$$

$$\theta^k \in R^{C \times F} \Rightarrow k\text{번째 layer의 가중치 행렬.}$$

$\sigma \Rightarrow$ activation function.

Example

Class의 수가 5개인 node classification.

$$k=3, F_1=30, F_2=20, G=\text{ReLU}$$

입력값: 총 30개의 노드, 40개의 feature $X \in \mathbb{R}^{30 \times 40}$

$$H^{(0)} = X \in \mathbb{R}^{30 \times 5}$$

$$H^{(1)} = \text{ReLU}(\hat{A} H^{(0)} \theta^{(1)}) \in \mathbb{R}^{30 \times 30}$$

$$H^{(2)} = \text{ReLU}(\hat{A} H^{(1)} \theta^{(2)}) \in \mathbb{R}^{30 \times 20}$$

$$H^{(3)} = \text{softmax}(\hat{A} H^{(2)} \theta^{(3)}) \in \mathbb{R}^{30 \times 5}$$

mini batch 방식으로 학습 불가. \therefore data가 큰 경우 학습이 쉽지 않음.

I. Normalized Adjacency Matrix의 eigenvalue는 $[0, 1]$ 이다.

(1) A의 가장 큰 eigenvalue 범위 -

A 가 undirected graph(G)의 adjacency matrix이고 λ_1 이 A 의 가장 큰 eigenvalue라고 하자. 이때, 아래 식이 성립한다.

$$d_{\text{avg}} \leq \lambda_1 \leq d_{\text{max}}$$

d_{avg} : G 의 평균 degree.

d_{max} : G 의 최대 degree

[증명 1]

v_1 (eigen vector) $\longleftrightarrow \lambda_1$ (eigenvalue)

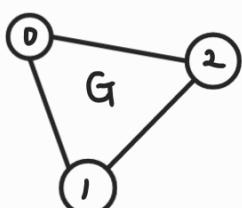
j 번째 노드는 모든 i 에 대해 $v_1(j) \geq v_1(i)$ 가 성립한다고 하자.

$$\lambda_1 v_1(j) = (Av_1)(j)$$

$$= \sum_{(i,j) \in E(G)} v_1(i) \leq \sum_{(i,j) \in E(G)} v_1(j)$$

$$= \deg(j) v_1(j) \leq d_{\text{max}} v_1(j)$$

About $\sum_{(i,j) \in E(G)} v_1(i) \leq \sum_{(i,j) \in E(G)} v_1(j)$ G로부터 계산한 A의 첫번째 eigenvector.



$$A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}, \quad \boxed{v_1} = \begin{bmatrix} v_1(1) \\ v_1(2) \\ v_1(3) \end{bmatrix}$$

$$\text{if } j=2 : v_1(2) \geq v_1(i), i \in [1,3]$$

$$\sum_{(i,j) \in E} v_1(i) = 1 \times v_1(1) + 1 \times v_1(3)$$

$$\sum_{(i,j) \in E} v_1(i) \leq \sum_{(i,j) \in E} v_1(2)$$

[증명 2]

모든 벡터의 원소가 1인 \vec{x} 에 대해 A 에 대한 레일리 쿼트(Rayleigh quotient)를 적용하면 다음이 성립한다.

$$\begin{aligned} N_1 &= \max_x \frac{\vec{x}^T A \vec{x}}{\vec{x}^T \vec{x}} \geq \frac{|\vec{1}^T A |}{|\vec{1}|} \\ &= \frac{\sum_{(i,j) \in E(G)} A(i,j)}{n} \\ &= \frac{\sum_i d(i)}{n} \\ &= d_{\text{avg}} \end{aligned}$$

2. Normalized A 의 eigenvalue 범위는 $[0, 2]$ 이다.

$$\text{normalized } A : \tilde{A} = D^{-1/2} A D^{1/2}$$

$$\tilde{L} = I - \tilde{A}$$

$$\begin{aligned} \tilde{L} &= I - \tilde{A} \\ &= D^{-1/2} (D - A) D^{-1/2} \\ &= D^{-1/2} L D^{-1/2} \end{aligned}$$

A 의 eigenvalue 범위: $[0, 2]$

$\tilde{A} \rightarrow$ normalized는 가장 큰 eigenvalue의 값을 1로 만들겠다는 뜻.

\tilde{A} 의 eigenvalue: $d_1 \geq \dots \geq d_n \quad \left| \begin{array}{l} 1 = d_1 \geq \dots \geq d_n \geq -1 \end{array} \right.$

\tilde{L} 의 eigenvalue: $\lambda_1 \leq \dots \leq \lambda_n \quad \left| \begin{array}{l} 0 = \lambda_1 \leq \dots \leq \lambda_n \leq 2 \end{array} \right.$

$X = D^{-\frac{1}{2}}v \rightarrow \tilde{L}$ 의 eigenvalue가 0이 될 수 있음.

(v 는 L 의 eigenvector)

$$\begin{aligned}\tilde{L}(D^{\frac{1}{2}}v) &= D^{-\frac{1}{2}}L\cancel{D}^{-\frac{1}{2}} \cdot D^{\frac{1}{2}}v \\ &= D^{-\frac{1}{2}}v \\ &= 0\end{aligned}$$

v 는 0의 값을 갖는 eigenvalue에 대응하는 L 의 eigenvector이며 $D^{\frac{1}{2}}v$ 에 해당하는 \tilde{L} 의 eigenvalue는 0이다. 이 값이 가장 작은 값임을 보이기 위해 \tilde{L} 가 positive semi-definite임을 증명한다. positive semi definite는 모든 $x \in \mathbb{R}^n$ 에 대해 $x^T \tilde{L} x$ 의 결과가 항상 0보다 크거나 같은 값을 띠는 것을 말한다.

$$\begin{aligned}x^T \tilde{L} x &= x^T (I - \tilde{\lambda}) x \\ &= \sum_{i \in V} x(i)^2 - \sum_{(i,j) \in E} \frac{2x(i)x(j)}{\sqrt{d(i)d(j)}}\end{aligned}$$

$$= \sum_{(i,j) \in E} \left(\frac{x(i)}{\sqrt{d(i)}} - \frac{x(j)}{\sqrt{d(j)}} \right)^2 \geq 0$$

$\Rightarrow \tilde{L}$ 가 positive semi-definite이고 $\lambda_1 = 0$ 임을 보였으나.

$\alpha_1 \leq 1$ 임을 보이기 위해 positive semi-definite인 \tilde{L} 을 활용하면 모든 $x \in \mathbb{R}^n$ 에 대해 다음이 성립한다.

$$x^T (I - \tilde{A}) x \geq 0 \rightarrow x^T x - x^T \tilde{A} x \geq 0 \rightarrow 1 \geq \frac{x^T \tilde{A} x}{x^T x}$$

$$\therefore 1 \geq \alpha_1$$

레일리 몫을 통해 α_1 의 상한선을 나타낼 수 있다. 위 식은 $x = D^{1/2}V$ 를 다시 대입해보면 앞서 언급한 내용을 활용해서 \tilde{A} 의 max eigenvalue가 1임을 알 수 있다.

$$x^T \tilde{L} x = 0 \rightarrow x^T (I - \tilde{A}) x = 0 \rightarrow x^T x = x^T \tilde{A} x$$

이와 비슷하게 α_n 의 하한선을 구하기 위해 positive semi-definite인 $I + \tilde{A}$ 를 적용하면

$$x^T (I + \tilde{A}) x \geq 0 \rightarrow x^T x + x^T \tilde{A} x \geq 0 \rightarrow \frac{x^T \tilde{A} x}{x^T x} \geq -1$$

$$\therefore \alpha_n \geq -1$$

마지막으로 $x^T (I + \tilde{A}) x \geq 0$ 을 \tilde{L} 에 대해 나타내면 레일리 몫을 통해 λ_n 의 상한선에 대해 나타낼 수 있다.

$$-x^T \tilde{A} x \leq x^T x \rightarrow x^T I x - x^T \tilde{A} x \leq 1 x^T x \rightarrow \frac{x^T \tilde{L} x}{x^T x} \leq 2$$

$$\therefore \lambda_n \leq 2$$

2. Renormalization Trick.

$$I_n + D^{-1/2} A D^{-1/2} \rightsquigarrow S_1\text{-order.}$$

$$S_1\text{-order} = 2I - \tilde{L}$$

S_r^K -order 는 filter coefficient가 $(2-\lambda_i)^K$ 인 값을 가진다. 여기서 λ_i 는 \tilde{L} 의 eigenvalue이다.

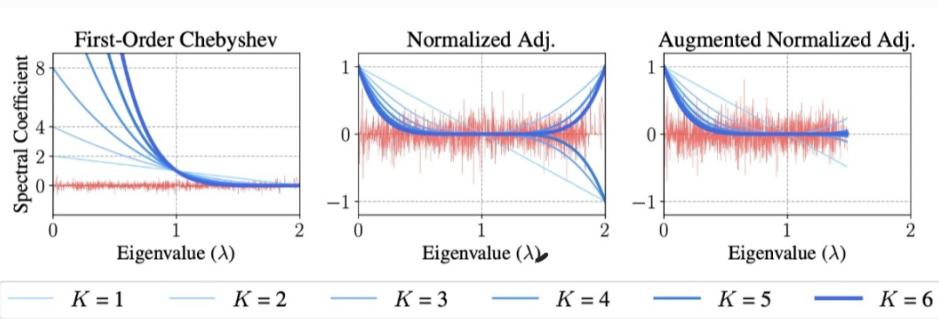


Figure 2. Feature (red) and filters (blue) spectral coefficients for different propagation matrices on Cora dataset (3rd feature).

그림 5. Simplifying GCN에서 실험한 augmented normalized adjacency의 효과

$\lambda_i < 1$ 에서 K 가 커짐에 따라 filter coefficient 값이 급격히 커진다. 이를 방지하기 위해 renormalization trick을 통해 eigenvalue의 크기를 줄인다.

$$\tilde{S}_{adj} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} \quad (\tilde{A} = A + I, \tilde{D} = D + I)$$

$$\tilde{L} = I - \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$$

이때 renormalization trick을 적용한 filter coefficient는 $\hat{\phi}(\tilde{\lambda}_i) = (1 - \tilde{\lambda}_i)^K$ 이다. ($\tilde{\lambda}_i$ 는 \tilde{L} 의 eigen value)

Self-loop를 추가하기 되면 최대 eigenvalue 값이 즐가된다.

[Theorem]

A 가 undirected graph G 에 대한 adjacency matrix이고
이에 대한 degree matrix는 D 라고 하자. 이 때 augmented adjacency
matrix를 $\tilde{A} = A + rI$ $r \geq 0$ 으로 나타내고 이에 대한 degree matrix는
 \tilde{D} 이다. 또한 $\tilde{L} = I - D^{-1/2} \tilde{A} D^{-1/2}$ 의 가장 작은 eigenvalue λ_1
가장 큰 eigenvalue를 각각 λ_1, λ_n 이라고 한다. 이 때 다음 식이 성립한다.

$$0 = \lambda_1 = \tilde{\lambda}_1 < \tilde{\lambda}_n < \lambda_n$$